


## [Chap 4] 데이터의 대표값



### 기술적 분석(descriptive statistics)


---

- 기술적 분석
  - 현상을 기술(describe) 또는 설명하는 방법론
- 기술적 분석 방법론의 필요성
  - 뇌(brain)와 인지(recognition) 용량의 한계
    - 단위 시간당 눈으로 보거나 귀로 듣고, 머리속에 넣고 그 경향을 인지할 수 있는 데이터량은 극히 제한적임
  - 대량의 데이터를 일목요연하게 정리해서 인지할 수 있는 방법론 필요
- 대표적 방법
  - 지표화(평균, 중앙값, 표준편차 등)
  - 시각화(visualization)

# 대표값

- 평균(mean)

- 데이터를 모두 더해서 개수로 나눈 값
- 가장 보편적으로 사용되나, 극단적인 값에 매우 취약함
- 예) 어떤 MBA의 졸업생 첫 해 연봉
  - 7천만 원, 6천만 원, 8천 5백만 원, 6천 5백만 원, 6천만 원, 5억 원
  - 평균 1억 4천만원 (전혀 사실적이지 않음)
- 가구소득 평균의 예
  - 우리나라의 가구당 평균소득은 약 6천만 원(5,924만 원)으로 나타나 있지만, 사실은 가구 중 절반이 4,652만원 이하의 소득



[그림 4-1] 가구소득의 비대칭적 분포 (자료: 통계청 2020년 가계금융복지조사)

3

# 대표값 (계속)

- 중앙값(median)

- 자료의 중앙에 있는 값
- 극단값이나 분포의 비대칭에 크게 영향을 받지 않음
- 예) 어떤 MBA의 졸업생 첫 해 연봉
  - 7천만 원, 6천만 원, 8천 5백만 원, 6천 5백만 원, 6천만 원, 5억 원
  - 중앙값 6,250만원 (훨씬 현실적임)
- 한국의 가구당 소득의 중앙값은 4,652만 원
  - 가구 평균소득인 5,924만 원과 비교하면 현실과의 괴리감이 훨씬 적음
  - 가구소득 분포가 오른쪽 꼬리가 긴 형태여서 중앙값이 평균보다 낮게 나타남

- 최빈값(mode)

- 가장 자주 나타난 값을 대표값으로 두는 것
  - '1, 2, 3, 3, 4, 5'의 경우 최빈값은 3
- 최빈값은 범주형 자료에서 유용하게 사용
  - 예) 단어별 출현 빈도를 보고 가장 자주 등장한 단어를 식별

4

# 데이터의 변동성(variability)

- 예) 공정의 설계방식 A, B, C 모두 평균 소요시간이 5분이라고 가정
  - 그러면 세 공정의 소요시간은 동일하다고 판단해도 되는가?
  - A, B, C 각각의 공정 소요시간을 세 번씩 측정하여 A : (5, 5, 5), B : (4, 5, 6), C : (3, 5, 7) 을 얻었다면?
    - 공정통제의 관점에서, A와 C는 판이하게 다른 고려가 필요
    - 평균이 같다고 A, B, C 공정의 소요시간이 같다고 볼 수 없음
- A, B, C 세 데이터를 다르게 만드는 것은 값들의 변동성(variability)임
  - '평균이 5분'이라는 표현 안에는 데이터 값의 전반적인 크기에 대한 정보만 있을 뿐, 값의 변동성에 대한 정보는 담겨있지 않음
  - 값의 크기와 변동성 중에, 변동성이 비즈니스 의사결정에 더 큰 영향을 미치는 경우가 많음
- 변동성을 표현하는 지표
  - 분산(variance)과 표준편차(standard deviation)가 대표적
  - 표준편차가 많이 사용됨

5

## 표준편차(standard deviation)

- A, B, C 공정시간의 표준편차

A: (5, 5, 5)

- 평균:  $(5+5+5)/3=5$
- 분산:  $\{(5-5)^2 + (5-5)^2 + (5-5)^2\}/(3-1)=0$
- 표준편차:  $\sqrt{0}=0$

B: (4, 5, 6)

- 평균:  $(4+5+6)/3=5$
- 분산:  $\{(4-5)^2 + (5-5)^2 + (6-5)^2\}/(3-1)=1$
- 표준편차:  $\sqrt{1}=1$

C: (3, 5, 7)

- 평균:  $(3+5+7)/3=5$
- 분산:  $\{(3-5)^2 + (5-5)^2 + (7-5)^2\}/(3-1)=4$
- 표준편차:  $\sqrt{4}=2$

6

# 데이터의 크기와 변동성

- 앞의 예에서, A 공정은 대략  $5 \pm 0$ , B는  $5 \pm 1$ , C는  $5 \pm 2$  정도의 변동폭을 갖는 것으로 생각할 수 있음
  - 표준편차를 평균에 더하고 빼 범위는 해당 데이터값의 변동범위의 약 70% (더 정확히는 68%)에 해당
    - '이 값은 **대개** 그 범위에서 나온다'
  - 표준편차의 두 배(더 정확히는 1.96배)를 평균에서 더하고 빼면 95% 신뢰구간이 됨
    - '이 값은 **거의** 그 범위에서 나온다'
- A, B, C 세 개의 숫자는 동일하지 않다!
  - 크기는 같더라도 변동성이 서로 다른 숫자들은 동일하게 취급할 수 없음
  - 데이터의 세계에서는, 어떤 값을 보든, 숫자의 앞면(크기)과 뒷면(변동성)을 동시에 고려해야 함

7

## [파이썬 실습] 데이터 추출하기

- 데이터 읽어오기

**예제** ex4-1.py (a)

```
1 import pandas as pd
2 b = pd.read_csv('buylov.csv')
3 print(b)
```

- 특정 열의 추출

**예제** ex4-1.py (b)

```
1 import pandas as pd
2 b = pd.read_csv('buylov.csv')
3 print(b['BGiftPrice'])
```

8

# 특정 열의 값에 따라 데이터를 구분

- Role의 값에 따라 데이터를 구분
  - 선물을 준 사람(Giver)의 데이터는 bg, 받은 사람(Receiver)의 데이터는 br이라는 변수에 구분하여 저장

**예제** ex4-2.py

```
1 import pandas as pd
2 b = pd.read_csv('buylov.csv')
3 bg = b[b['Role']=='Giver']
4 br = b[b['Role']=='Receiver']
5 print('< Giver Data >')
6 print(bg)
7 print('< Receiver Data >')
8 print(br)
```

9

# 대표값 구하기

- 생일선물 가격의 평균 구하기

**예제** ex4-3.py (b)

```
1 import pandas as pd
2 import numpy as np
3 b = pd.read_csv('buylov.csv')
4 print(b['BGiftPrice'])
5 print('평균 :', np.mean(b['BGiftPrice']))
```

- BGiftPrice, 즉 생일선물의 가격이 평균적으로 약 124.59달러로 나타남

# 대표값 구하기

- 생일선물 가격의 중앙값

**예제** ex4-3.py (c)

```
1 import pandas as pd
2 import numpy as np
3 b = pd.read_csv('buylov.csv')
4 bp = b['BGiftPrice']
5 print(bp)
6 print('평균 :', np.mean(bp))
7 print('중앙값 :', np.median(bp))
```

- 평균은 약 124.59달러이지만, 중앙값은 93.0달러로 계산됨
- 평균과 중앙값의 차이가 상당히 큼
  - 중앙값은 극단값의 영향을 받지 않음을 감안하면, 극단적으로 비싼 생일선물들로 인해 평균값이 높은 쪽으로 끌려갔을 것이라는 점을 짐작할 수 있음

11

# 표준편차 구하기

- 표준편차: 값의 변동성을 나타내는 대표적인 지표

**예제** ex4-4.py

```
1 import pandas as pd
2 import numpy as np
3 b = pd.read_csv('buylov.csv')
4 bp = b['BGiftPrice']
5 print(bp)
6 print('평균 :', np.mean(bp))
7 print('중앙값 :', np.median(bp))
8 print('표준편차 : ', np.std(bp))
```

- 표준편차는 114.64로, 생일선물 가격 범위가 넓게 퍼져 있음을 시사
  - 5장에서 시각화를 통해 확인

12