

[Chap 5] 데이터의 시각화 (Visualization)



데이터 시각화(data visualization)

- 데이터 속에 숨어있는 의미를 추출하여 그래프 등의 시각적인 도구로 표현하는 것
- 모든 분석의 출발점
- 잘 만들어진 시각화만으로도 데이터 분석의 절반 이상이 완성
 - 데이터에 내포된 의미를 시각화하는 과정에서 데이터의 패턴과 의미를 충분히 고찰할 수 있게 됨
- 데이터 분석을 위한 기본적인 3대 시각화 도구
 - 히스토그램(histogram)
 - 상자그림(boxplot)
 - 산점도(scatterplot)

[사례 1] 다산 정약용 선생


- 1795년, 정조는 사도세자의 능(현릉원, 顯隆園)에 그간 심은 나무가 몇 그루나 되는지, 주변 고을에서 얼마나 나무를 심었는지 등을 하문
 - 공문(식목부, 植木簿)이 수레를 가득 채웠지만 정조의 물음에 아무도 답을 하지 못함
- 정조는 정약용에게 나무의 숫자를 정리하라 명함
- 정약용은 이를 표로 정리
 - 여덟 고을 각각에 대한 여덟 장의 종이를 준비
 - 각 종이에 열 제목은 연도, 행 제목은 나무 종류로 표 작성
- 이를 종합하여 고을(행)별 연도(열)별 총괄표 작성
 - 총 1200만 9972그루
 - 정조는 크게 칭찬하며 오랫동안 감탄하였다고 알려짐
- 곡산부사로 부임하였을 때에도 가구별 경제상황을 표로 정리하여 수탈을 방지한 사례



3

[사례 2] 나이팅게일의 로즈 차트

- 야전 병원을 운영하면서 병사들이 부상 자체보다 병원 감염으로 사망하는 상황을 보고, 병원의 위생 환경 개선을 위한 본국 지원 설득 필요
- 병원내 감염으로 병사들이 사망하는 현황을 한 눈에 전달하기 위해 시각화 도구 개발
 - 로즈 다이어그램(Rose diagram)
- 도표로부터 병원 감염으로 인한 사망이 부상 자체보다 압도적으로 많음을 한 눈에 확인할 수 있음
 - 시각화를 통한 의사소통을 통해 병원 환경 개선을 위한 본국의 지원을 획득하여 많은 병사들의 생명을 구함
- 시각화를 통한 의사소통의 대표적 성공 사례로 꼽힘




[그림 5-2] 나이팅게일의 로즈 다이어그램 (자료 : <https://www.uh.edu/engines/epi1712.htm>)

4

[사례 3] 인구 피라미드

- 세로로 연령을, 가로로는 해당 연령의 남녀 인구 수를 가로 선의 길이로 나타내고 있는 히스토그램
- 1970년대 초반까지 높은 출산율로 베이비 붐 세대 형성 확인
 - 초중고 과밀학급, 높은 대학진학 장벽, 부동산 가격의 급등 등 사회현상 초래
- 이후 출산율의 급감으로 저출산이 국가적 문제로 대두되는 상황이 명확히 시각화
 - 저출산 지속시 2040년의 인구구조는 초고령사회의 도래를 예측
 - 사회 전반과 경제 및 기업환경에 엄청난 변화 예고 및 중요한 시사점 제공




[그림 5-3] 인구 피라미드

5


데이터 시각화를 위한 프로그램 기초

- matplotlib의 설치
 - cmd(명령 프롬프트)를 실행 후 'pip install matplotlib' (MacOS: pip3)



- 기초적인 시각화 예제

```
1 import matplotlib.pyplot as plt
2 x=[1,2,3,2,3,4]
3 plt.plot(x)
4 plt.show()
```



[그림 5-4] 기본적인 plot 함수의 출력

- (1행) matplotlib.pyplot을 plt라는 짧은 이름으로 불러옴
- (3행) plot함수로 x의 값을 그래프로 준비
- (4행) show함수로 준비된 그래프를 화면에 출력


6

데이터 시각화를 위한 프로그램 기초 (계속)

- $y = x^2$ 의 그래프 출력

예제 ex5-1.py

```
1 import matplotlib.pyplot as plt
2 x=[-5, -4, -3, -2, -1, 0, 1, 2, 3, 4, 5]
3 y=[]
4 for v in x:
5     y.append(v**2)
6 plt.plot(x,y)
7 plt.show()
```




[그림 5-6] plot을 이용한 이차함수 그래프

- (4행) 리스트 x에서 순차적으로 값을 꺼내어 v에 대입
- (5행) 리스트 y에 v의 제곱을 순차적으로 덧붙임
- (6행) plot함수로 (x,y)를 차례로 이은 그래프 준비

7

데이터 시각화를 위한 프로그램 기초 (계속)

- `plt.plot(x, y, marker='X')` : 각 점을 x표로 표시
- `plt.plot(x, y, marker='X', linestyle='None')` : 중간의 선 제거
- `plt.plot(x, y, marker='X', linestyle='--')` : 선을 점선으로 변경




[그림 5-7] plot에서 다양한 marker의 사용

데이터 시각화 실습: 히스토그램

- 히스토그램(histogram) : 데이터 분포 시각화
- buylov.csv에서 생일 선물가격의 히스토그램 출력

예제 ex5-2.py

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 b = pd.read_csv('buylov.csv')
4 bp = b['BGiftPrice']
5 plt.hist(bp)
6 plt.show()
```



[그림 5-8] 히스토그램 예시


- (3행) buylov.csv를 읽어서 b에 저장
 - (4행) b에서 'BGiftPrice' 열만 뽑아서 bp에 저장
 - (5행) bp의 히스토그램을 준비
- 선물 가격이 대부분 낮은 가격대에서 분포하고 오른쪽 꼬리가 길게 나타남
 - 4장에서 선물 가격의 평균은 124.6달러, 중앙값은 93.6달러였던 것과 대응

9

데이터 시각화 실습: 상자그림

- 상자그림(boxplot): 여러 값의 분포를 동시에 비교할 때 자주 사용
- 생일선물가격에 대한 상자그림 예

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 b = pd.read_csv('buylov.csv')
4 bp = b['BGiftPrice']
5 plt.boxplot(bp)
6 plt.show()
```



[그림 5-9] 상자그림 예시

- (3행) buylov.csv를 읽어서 b에 저장
- (4행) b에서 'BGiftPrice' 열만 뽑아서 bp에 저장
- (5행) boxplot(bp): bp의 값을 상자그림으로 준비

데이터 시각화 실습: 상자그림 (계속)

- 상자그림은 히스토그램을 위에서 바라본 것임
 - 히스토그램의 높은 부분이 두꺼운 사각형, 낮은 부분은 선으로 표시됨
- 가운데 두꺼운 선은 중앙값(median)
- 상자의 아래위 경계는 각각 데이터의 첫번째 사분위수(first quartile)와 세번째 사분위수(third quartile)
 - 상자의 높이 범위에 데이터의 주류(전체 데이터의 50%)가 포함됨
 - 상자높이: IQR(Inter-Quartile Range)
- 수염의 길이는 상자 아래위 끝에서 시작해서 IQR의 1.5배까지 뻗어 있음
 - 예에서 아래쪽 수염은 데이터 최소값까지 잘려서 짧게 나타남
- 수염 바깥의 데이터는 이상치로 의심되는 값들(suspicious outliers)
 - IQR의 3배 범위 바깥의 값은 이상치로 강력히 의심(strongly suspicious outliers)

11

데이터 시각화 실습: 상자그림 (계속)

- 여러 데이터를 비교할 때 더욱 유용

예제 ex5-3.py

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 b = pd.read_csv('buylov.csv')
5 bg = b[b['Role']=='Giver']
6 br = b[b['Role']=='Receiver']
7 print('<준 사람 선물가격>')
8 print('평균 :', np.mean(bg['BGiftPrice']))
9 print('중앙값:', np.median(bg['BGiftPrice']))
10 print('<받은 사람 선물가격>')
11 print('평균 :', np.mean(br['BGiftPrice']))
12 print('중앙값:', np.median(br['BGiftPrice']))
13 plt.boxplot([bg['BGiftPrice'], br['BGiftPrice']], labels=['Giver', 'Receiver'])
14 plt.show()
```

bg와 br에 선물을 준 사람과 받은 사람의 데이터를 구분해서 넣음

준 사람과 받은 사람의 선물가격 평균과 중앙값을 비교
- 선물을 받는 사람은 실제 선물가격보다 더 높은 가치로 느낀다는 해석이 가능


boxplot에 두 값 bg['BGiftPrice']와 br['BGiftPrice']를 넘겨 상자그림으로 비교 출력
- 상자그림 시각화는 더욱 명확하게 두 값의 차이를 보여줌

12

데이터 시각화 실습: 상자그림 (계속)

- 예제 5-3의 출력 결과

<준 사람 선물가격>
평균 : 105.84328358208955
중앙값: 75.5
<받은 사람 선물가격>
평균 : 148.98058252427185
중앙값: 133.0



[그림 5-10] 상자그림을 이용한 데이터 비교

13

데이터 시각화 실습: 산점도

- 산점도(scatterplot) : 두 개의 데이터 계열 사이의 관계를 시각화
- 선물 가격과 고마운 정도의 관계를 분석

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 b = pd.read_csv('buylov.csv')
4 plt.scatter(b['BGiftPrice'], b['Apprec-7'])
5 plt.show()
```

– (4행) x축에 선물가격, y축에 고마운 정도를 나타낸 산점도를 준비

- 출력된 산점도에서는 선물 가격과 고마운 정도 사이에 명확한 패턴이 보이지 않음



[그림 5-11] 산점도 예시

14

데이터 시각화 실습: 산점도 (계속)


- 선물을 준 사람과 받은 사람의 데이터를 번호 1, 2로 분리하여 도식화

예제 ex5-4.py


```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 b = pd.read_csv('buylov.csv')
4 bg = b[b['Role']=='Giver']
5 br = b[b['Role']=='Receiver']
6 plt.figure(1)
7 plt.scatter(bg['BGiftPrice'], bg['Apprec-7'])
8 plt.figure(2)
9 plt.scatter(br['BGiftPrice'], br['Apprec-7'])
10 plt.show()
```

- (4~5행) 선물을 준 사람과 받은 사람의 데이터를 bg, br로 구분
- (6~7행) 그림번호를 1로 하여 bg에서 선물가격과 고마운 정도의 산점도를 준비
- (8~9행) 그림번호를 2로 하여 br에서 선물가격과 고마운 정도의 산점도를 준비
- (10행) 그림번호 1, 2를 동시에 화면에 출력

- 선물을 준 쪽은 높은 상관성 관찰,
받은 쪽은 상관성이 안보임
 - 선물을 준 사람들은 비싼 선물에 대해 상대방이 고마워할 것을 기대했겠지만, 받은 사람들은 가격과 고마운 정도가 상관이 없음이 관찰됨



(a) 선물을 준 사람의 데이터



(b) 선물을 받은 사람의 데이터

[그림 5-12] 역할에 따라 구분된 산점도