

[Chap 6] 예측적 분석과 학습 데이터 구조



예측적 분석(predictive analytics)

- 관찰할 수 있는 데이터를 기반으로 보이지 않는 값을 예측하는 방법을 제공
- 대부분 미래를 예측하지만, 반드시 미래가 대상이 아닐 수도 있음
 - 현재 가지고 있는 데이터를 바탕으로 미래를 예측
 - 예) 미래 주가 예측, 수요예측
 - 현재 존재하는 값이지만 우리에게 보이지는 않는 값을 예측
 - 예) 기업의 재무적 데이터 등을 바탕으로 주식의 내재가치를 예측

KNN(k-Nearest Neighbor) 알고리즘

- k-최근접 이웃 모형이라고도 함
- k개의 가장 가까운 이웃들의 다수를 따르는 방식으로 예측
- 실습을 위해 사이킷런(scikit-learn) 설치 필요
 - pip install sklearn (MacOS: pip3 install sklearn)



```
명령 프롬프트
Microsoft Windows [Version 10.0.19044.1826]
(c) Microsoft Corporation. All rights reserved.

C:\WINDOWS\system32>pip install sklearn_
```

3

실습 데이터(와인 데이터셋) 살펴보기

- 와인 데이터셋을 불러와서 내용 출력하기

```
1 from sklearn import datasets
2 dataset = datasets.load_wine()
3 print(dataset)
```

- (1행) sklearn 패키지 전체 대신 datasets 모듈만 import

```
from (패키지명) import (모듈명)
```

- 와인 데이터셋의 데이터 설명만 출력하기

```
1 from sklearn import datasets
2 dataset = datasets.load_wine()
3 print(dataset.DESCR)
```

- 총 178가지의 와인에 대한 데이터
- 각 와인별 특성값 13가지
 - 알코올 도수(Alcohol), 사과산 농도(Malic acid) 등
- 해당 와인의 클래스(등급) : 0, 1, 2의 3가지

4

실습 데이터(와인 데이터셋) 살펴보기(계속)

- 와인 데이터셋의 속성(attribute) 종류 출력하기

```
1 from sklearn import datasets
2 dataset = datasets.load_wine()
3 print(dir(dataset))
```

```
['DESCR', 'data', 'feature_names', 'target', 'target_names']
```

- DESCR : 데이터셋 설명
- data : 178개 와인 각각에 대해 13개의 특성값

- data 속성만 출력하기

```
1 from sklearn import datasets
2 dataset = datasets.load_wine()
3 print(dataset.data)
```

```
[[1.423e+01 1.710e+00 2.430e+00 ... 1.040e+00 3.920e+00 1.065e+03]
 [1.320e+01 1.780e+00 2.140e+00 ... 1.050e+00 3.400e+00 1.050e+03]
 [1.316e+01 2.360e+00 2.670e+00 ... 1.030e+00 3.170e+00 1.185e+03]
 ...]
```

5

실습 데이터(와인 데이터셋) 살펴보기(계속)

- data 속성 자세히 살펴보기

예제 ex6-1.py

```
1 from sklearn import datasets
2 dataset = datasets.load_wine()
3 print("data type=",type(dataset.data))
4 print("data shape=",dataset.data.shape)
5 print("first row of data=",dataset.data[0])
```

```
data type= <class 'numpy.ndarray'>
data shape= (178, 13)
first row of data= [1.423e+01 1.710e+00 2.430e+00 1.560e+01 1.270e+02 2.800e+00
 3.060e+00 2.800e-01 2.290e+00 5.640e+00 1.040e+00 3.920e+00 1.065e+03]
```

- (3행) 데이터의 type을 출력: numpy 다차원배열
- (4행) 데이터의 행과 열을 출력: 178행 13열
- (5행) 데이터의 첫 행(data[0])을 출력 : 첫 번째 와인의 13개 특성값이 출력
 - 1.423e+01 = 14.23 (지수적 표현)

6

와인 데이터의 2차원 시각화

- 와인 데이터를 pandas 데이터프레임으로 옮기기

예제 ex6-4.py

```
1 import pandas as pd
2 from sklearn import datasets
3 dataset = datasets.load_wine()
4 d = pd.DataFrame(dataset.data, columns=dataset.feature_names)
5 d['target'] = dataset.target
6 print(d)
```

- (4행) dataset.data로 새로운 데이터프레임을 생성.
이 때 각 열의 제목을 feature_names 속성에 나타난 각 특성의 이름으로 설정
- (5행) 앞에서 생성된 데이터프레임에 target이라는 새로운 열을 추가하고,
그 열의 값으로는 dataset.target의 값을 넣음

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	...	proanthocyanins	color_intensity	hue	od280/od315_of_diluted_wines	proline	target
0	14.23	1.71	2.43	15.6	127.0	2.80	...	2.29	5.64	1.04	3.92	1065.0	0
1	13.20	1.78	2.14	11.2	100.0	2.65	...	1.28	4.38	1.05	3.40	1050.0	0
2	13.16	2.36	2.67	18.6	101.0	2.80	...	2.81	5.68	1.03	3.17	1185.0	0
3	14.37	1.95	2.50	16.8	113.0	3.85	...	2.18	7.80	0.86	3.45	1480.0	0
4	13.24	2.59	2.87	21.0	118.0	2.80	...	1.82	4.32	1.04	2.93	735.0	0
..	...	...	...	...	...	...	...	...	...	...	...	...	...


9

와인 데이터의 2차원 시각화 (계속)

- 'alcohol'과 'malic_acid' 특성으로 산점도 그리기

예제 ex6-5.py

```
1 import pandas as pd
2 from sklearn import datasets
3 dataset = datasets.load_wine()
4 d = pd.DataFrame(dataset.data, columns=dataset.feature_names)
5 d['target'] = dataset.target
6
7 import matplotlib.pyplot as plt
8 plt.scatter(d['alcohol'], d['malic_acid'])
9 plt.xlabel('alcohol')
10 plt.ylabel('malic_acid')
11 plt.show()
```



[그림 6-4] 와인 데이터의 alcohol과 malic_acid 산점도


- (7행) matplotlib.pyplot을 plt라는 이름으로 불러옴
- (8행) x축에 d['alcohol'], y축에 d['malic_acid']의 값으로 각 와인의 산점도 표시
- (9~10행) 가로축 및 세로축 제목 표시

와인 데이터의 2차원 시각화 (계속)

- 와인 등급별로 색상 구분하여 산점도 그리기

예제 ex6-7.py

```
...
6 d = pd.DataFrame(dataset.data, columns=dataset.feature_names)
7 d['target'] = dataset.target
8 groups = d.groupby('target')
9 for group_name, group_data in groups:
10     plt.scatter(group_data['alcohol'], group_data['malic_acid'], label=group_name)
11 plt.legend()
12 plt.show()
```



[그림 6-5] 와인 등급별로 구분된 산점도

- (8행) groupby 명령을 사용하여 target 의 값을 기준으로 그룹을 나눔
- (9행) for문을 사용하여 각 그룹 이름을 group_name, 해당 그룹 데이터프레임을 group_data에 저장
- (10행) 각 그룹의 group_data의 'alcohol' 열과 'malic_acid' 열의 값을 각각 x축과 y축으로 표시하고, group_name을 라벨로 설정하여 색상을 달리 함


11

와인 데이터의 3차원 시각화

- x축에 알코올 도수, y축에 사과산 농도, z축에 색상으로 3차원 산점도

예제 ex6-8.py

```
...
10 from mpl_toolkits.mplot3d import Axes3D
11 ax = plt.axes(projection = '3d')
12 for n, d in groups:
13     ax.scatter(d['alcohol'], d['malic_acid'], d['hue'], label=n)
14 plt.legend()
15 ax.set_xlabel('alcohol')
16 ax.set_ylabel('malic_acid')
17 ax.set_zlabel('hue')
18 plt.show()
```




[그림 6-6] 와인 데이터의 3차원 산점도

- (10행) 3차원 산점도를 위해 mpl_toolkits.mplot3d 패키지의 Axes3D 모듈을 사용
- (11행) 3차원 공간을 투영(projection)한 상태의 좌표축을 설정
- (12~13행) 각 등급별로 x축에 alcohol, y축에 malic_acid, z축에 hue 값으로 점을 찍음
- 마우스로 좌표축을 회전시키면서 살펴보면 2차원 산점도에서 등급들이 혼재되어 있던 영역이 사실은 z축(색상)으로 상당히 분리됨을 확인
 - 특성이 추가로 고려됨에 따라 구분(classification) 능력 향상

12

KNN의 개념

- 부근(neighbor)에 다수인 종류로 따라가면 대체로 맞을 것이라는 생각을 체계화
 - 도수 12, 사과산 2인 와인은 등급 1로 추정됨
 - (12, 2) 부근에는 거의 주황색(등급 1)의 와인이 분포하기 때문
 - (12.1, 3)의 부근에는 주황색(등급 1)이 많지만 초록색(등급 2)도 있음
 - 무조건 가장 가까운 점을 보고 판단하는 것은 위험
 - 그보다는 주변 몇 개의 점을 살펴보고 대세를 따르는 것이 더 안전할 것임
- KNN: 가장 가까운(nearest) k개의 점에서 다수를 차지하는 종류로 판단하는 방식
 - k=5라면 (12.1, 3)에서 가장 가까운 다섯 개를 기준으로 함
 - 가까운 주변 네 개가 주황색이고 하나가 초록색이므로, 다수인 주황색(등급 1)으로 판단
 - k의 값에 따라 예측 성능이 크게 좌우됨
 - k=1은 국지적인 주변의 특이한 상황에 휘둘리기 쉬움
 - k값을 변화시켜보면서 가장 예측력이 높아지는 k값을 찾는 것이 관건임



[그림 6-8] 도수 12.1, 사과산 3인 와인의 등급 판단

KNN 모형 구축

- 학습용 데이터 구축

```
1 import pandas as pd
2 from sklearn import datasets
3 dataset = datasets.load_wine()
4 d = pd.DataFrame(dataset.data, columns=dataset.feature_names)
5 d['target'] = dataset.target
6
7 x_train = d[['alcohol', 'malic_acid']]
8 y_train = d['target']
9 print("<Feature data>")
10 print(x_train)
11 print("<Target data>")
12 print(y_train)
```

```
<Feature data>
      alcohol  malic_acid
0      14.23         1.71
1      13.20         1.78
2      13.16         2.36
..      ...           ...
176     13.17         2.59
177     14.13         4.10
```

[178 rows x 2 columns]

```
<Target data>
```

```
0      0
1      0
2      0
```

```
..
176    2
177    2
```

Name: target, Length: 178, dtype: int32

- (7행) d에서 'alcohol'과 'malic_acid' 열만 x_train에 저장
- (8행) d에서 'target' 열만 y_train에 저장

KNN 모형 구축 (계속)

- 데이터를 KNN모델에 학습시켜 예측

```
예제 ex6-9.py
...
14 from sklearn.neighbors import KNeighborsClassifier
15 knn = KNeighborsClassifier(n_neighbors=5)
16 knn.fit(x_train, y_train)
17 x_pred=pd.DataFrame(data = [[12, 3]], columns=['alcohol','malic_acid'])
18 print(x_pred)
19 print('Predicted :', knn.predict(x_pred))
```

(앞부분 생략)

```
alcohol malic_acid
0      12         3
Predicted : [1]
```

- (14행) 사이킷런에서 KNN을 위한 KNeighborsClassifier 모듈을 불러옴
- (15행) k값에 해당하는 n_neighbors를 5로 설정
- (16행) 특성값 x_train과 정답값 y_train을 주고 학습
- (17행) [12, 3]에 대해 예측